Strategia ewolucyjna $(\mu + \lambda)$

Lidia Szczepkowska Numer indeksu: 355218

1 Opis implementowanych algorytmów

1.1 Strategia ewolucyjna $(\mu + \lambda)$

Zaimplementowano klasyczną strategię ewolucyjną $(\mu + \lambda)$ z samoadaptacją zasięgu mutacji. Algorytm minimalizuje funkcję celu przekazaną jako argument. Funkcja celu przyjmuje macierz punktów, w której każda kolumna odpowiada jednemu osobnikowi, i zwraca wektor wartości funkcji celu dla wszystkich ocenianych osobników. Schemat działania:

1. **Inicjalizacja** – generowanych jest μ osobników poprzez losowanie każdej współrzędnej z rozkładu jednostajnego na przedziale $[-100, 100]^n$. Każdy osobnik ma własny zasięg mutacji σ.

2. **Reprodukcja** – λ dzieci powstaje przez losowy (jednostajny) wybór rodziców spośród μ osobników.

3. **Mutacja z samoadaptacją** – najpierw mutowany jest zasięg:

   $$\sigma' = \sigma \cdot \exp(\tau \cdot \mathcal{N}(0, 1))$$

   gdzie $\tau = \frac{1}{\sqrt{2n}}$, a następnie punkt:

   $$x' = x + \sigma' \cdot \mathcal{N}(0, \mathbf{I})$$

   Punkty są obcinane do dziedziny $[-100, 100]^n$.

4. **Sukcesja** $(\mu + \lambda)$ – nowa populacja to μ najlepszych osobników spośród połączonych rodziców i potomków. Strategia ma charakter elitarny, co gwarantuje zachowanie najlepszego dotychczas rozwiązania.

Warunki stopu:

1. Wyczerpanie budżetu wywołań funkcji celu,

2. Stagnacja – brak poprawy najlepszej wartości przez 25 kolejnych pokoleń.

Algorytm jest stochastyczny (losowa inicjalizacja, losowy wybór rodziców, losowa mutacja), dlatego wszystkie eksperymenty powtarzane są wielokrotnie.

1.2 Gradient prosty

Zaimplementowano algorytm gradientu prostego. Dla zachowania porównywalności wyników wykorzystano taki sam budżet ewaluacji funkcji celu jak w strategii ewolucyjnej. Koszt jednej iteracji wynosi $2n + 1$ ewaluacji funkcji celu: $2n$ do numerycznego wyznaczenia gradientu oraz jedną do oceny nowego punktu. Przy budżecie równym $100n$ daje to około 50 iteracji. Kryteriami zatrzymania są wyczerpanie budżetu ewaluacji lub osiągnięcie odpowiednio małej normy gradientu.

2 Opis planowanych eksperymentów numerycznych

Badanie zbieżności przeprowadzono na trzech funkcjach celu: CEC 2017 F3, CEC 2017 F18, kwadratowej.

Parametry wspólne wszystkich eksperymentów:

- wymiarowości: $n = 10$ i $n = 30$,
- dziedzina: $[-100, 100]^n$,
- budżet: $FE_{\max} = 100 \cdot n$,
- 10 niezależnych powtórzeń każdej konfiguracji (różne ziarna generatora); raportowana jest średnia krzywa zbieżności oraz średnia $\pm$ odchylenie standardowe wyniku końcowego.

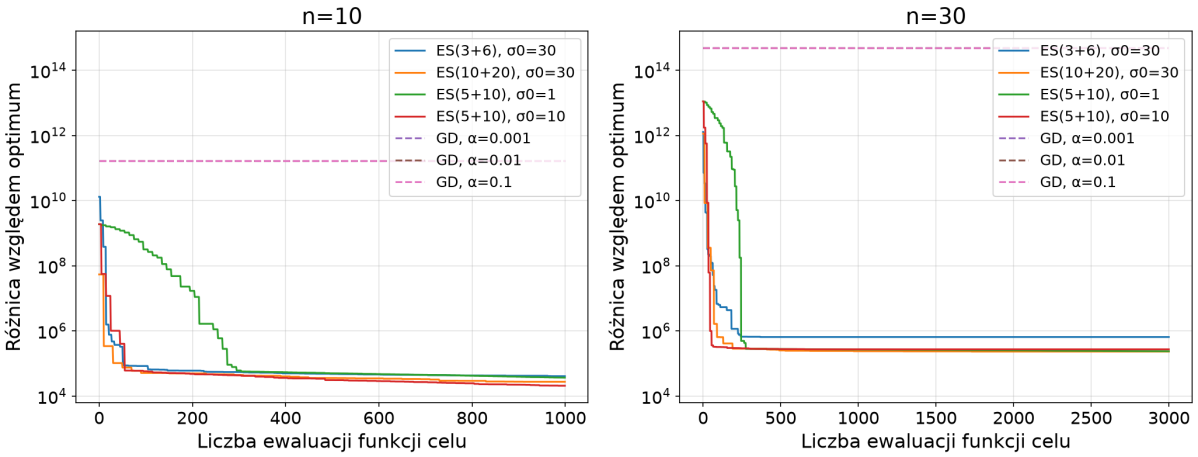
Plan eksperymentów:

1. **Wpływ parametrów ES** – porównano konfiguracje $(\mu + \lambda) \in \{(3 + 6), (10 + 20)\}$ przy $\sigma_0 = 30$ (wpływ rozmiaru populacji) oraz $\sigma_0 \in \{1, 10\}$ przy $(5 + 10)$ (wpływ początkowego zasięgu mutacji).
2. **Porównanie z gradientem prostym** – GD z krokami $\alpha \in \{0.001, 0.01, 0.1\}$ na tych samych funkcjach i z tym samym budżetem.

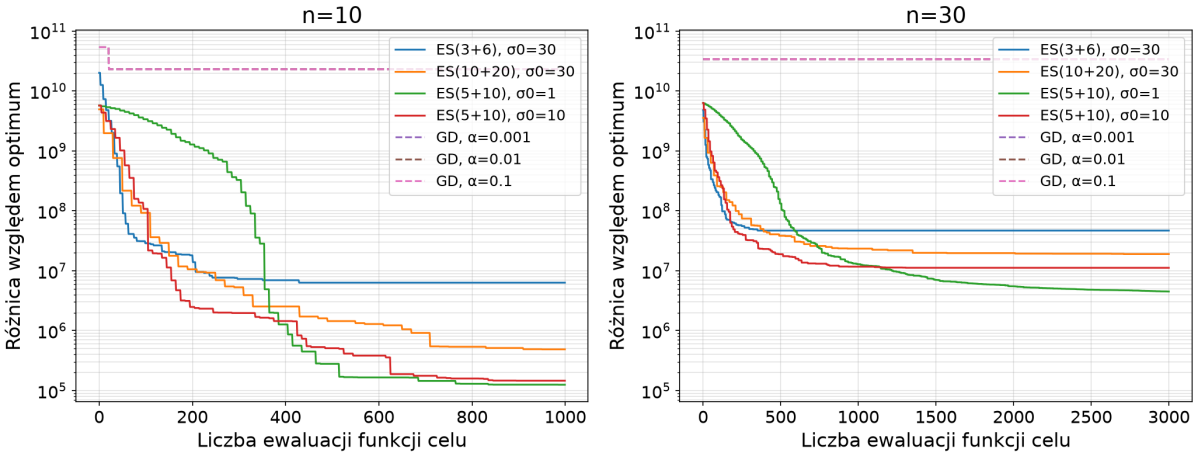
Miarą jakości jest błąd $f(x_{\text{best}}) - f^*$ (odległość od znanego optimum), rysowany w skali logarytmicznej w funkcji liczby ewaluacji funkcji celu.

3 Opis uzyskanych wyników

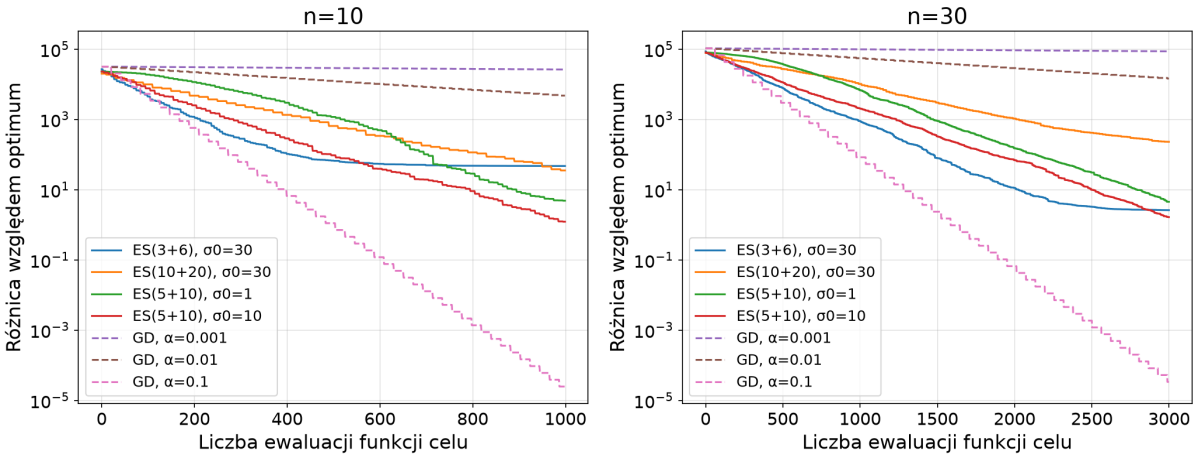
Wykresy zbieżności (średnia z 10 uruchomień):



Rysunek 1: Funkcja CEC2017_F3



Rysunek 2: Funkcja CEC2017_F18



Rysunek 3: Funkcja kwadratowa

Funkcja	n	Najlepsza konfiguracja	Średni wynik
CEC2017_F3	10	ES(5+10), $\sigma_0 = 10$	$2.09 \cdot 10^4$
CEC2017_F3	30	ES(10+20), $\sigma_0 = 30$	$2.31 \cdot 10^5$
CEC2017_F18	10	ES(5+10), $\sigma_0 = 1$	$1.27 \cdot 10^5$
CEC2017_F18	30	ES(5+10), $\sigma_0 = 1$	$4.50 \cdot 10^6$
Kwadratowa	10	GD, $\alpha = 0.1$	$2.46 \cdot 10^{-5}$
Kwadratowa	30	GD, $\alpha = 0.1$	$3.35 \cdot 10^{-5}$

Tabela 1: Najlepsze uzyskane wyniki dla badanych funkcji

Dla funkcji CEC2017 F3 oraz CEC2017 F18 najlepsze wyniki osiągały konfiguracje strategii ewolucyjnej. W przypadku funkcji kwadratowej najniższe wartości funkcji celu uzyskał algorytm gradientu prostego z krokiem $\alpha = 0.1$. Zaobserwowano również wpływ parametrów strategii ewolucyjnej, w szczególności początkowego zasięgu mutacji σ_0 oraz liczebności populacji.

4 Wnioski z przeprowadzonych badań

Przeprowadzone eksperymenty pokazały, że strategia ewolucyjna lepiej radzi sobie z trudnymi funkcjami wielomodalnymi i źle uwarunkowanymi niż algorytm gradientu prostego. Z kolei dla prostych i gładkich funkcji skuteczniejszy okazał się gradient prosty. Zaobserwowano również większą wrażliwość algorytmu gradientowego na dobór parametrów, podczas gdy strategia ewolucyjna wykazywała większą stabilność działania. Ze względu na stochastyczny charakter metod ewolucyjnych wyniki oceniano na podstawie średnich z dziesięciu niezależnych uruchomień.